

รายงานการวิจัยเชิงลึก: สถาปัตยกรรมทาง คณิตศาสตร์ พัฒนาการล่าสุด และคู่มือการ ประยุกต์ใช้งานแบบจำลอง Bayesian Knowledge Tracing ขั้นสูง

บทนำและภูมิทัศน์ของการติดตามความรู้ในระบบการศึกษาอัจฉริยะ

ในยุคแห่งการวิเคราะห์ข้อมูลทางการศึกษา (Educational Data Mining หรือ EDM) และการสร้างแบบจำลองทางปัญญา (Cognitive Modeling) ความท้าทายสูงสุดประการหนึ่งคือการอนุมานสถานะความรู้ที่แท้จริงของผู้เรียนจากพฤติกรรมที่สังเกตได้เพียงผิวเผิน ระบบการสอนเสริมอัจฉริยะ (Intelligent Tutoring Systems หรือ ITS) อาศัยความสามารถนี้ในการปรับแต่งหลักสูตรให้สอดคล้องกับผู้เรียนแต่ละบุคคลอย่างสมบูรณ์¹ แบบจำลองที่เป็นรากฐานสำคัญและได้รับการยอมรับอย่างกว้างขวางที่สุดในการประเมินความเชี่ยวชาญทางปัญญาดังแต่อดีตจนถึงปัจจุบันคือ Bayesian Knowledge Tracing (BKT) ซึ่งถูกเสนอขึ้นครั้งแรกในช่วงกลางทศวรรษ 1990 โดย Corbett และ Anderson และได้รับการพัฒนาขยายขอบเขตอย่างต่อเนื่องจนกลายเป็นสถาปัตยกรรมที่มีความซับซ้อนและทรงพลังในปัจจุบัน¹

แนวคิดหลักของ BKT คือการตีกรอบกระบวนการเรียนรู้ให้เป็นกระบวนการมาร์คอฟที่สังเกตได้บางส่วน (Partially Observable Markov Process) โดยพิจารณาว่าความรู้ของผู้เรียนเป็นตัวแปรแฝงทวิภาค (Binary Latent Variable) ซึ่งมีเพียงสองสถานะคือ "เชี่ยวชาญแล้ว" (Mastered) และ "ยังไม่เชี่ยวชาญ" (Not Mastered) สิ่งที่ระบบสามารถรับรู้ได้คือผลลัพธ์จากการตอบคำถามในแต่ละข้อที่แสดงผลออกมาในรูปแบบทวิภาคเช่นกัน (ถูกหรือผิด)¹ แม้ในปัจจุบันจะมีการเกิดขึ้นของแบบจำลองโครงสร้างข่ายงานประสาทเทียมเชิงลึก (Deep Knowledge Tracing หรือ DKT) ที่ใช้แบบจำลองเวกเตอร์แบบต่อเนื่องในการทำนาย แต่ BKT ยังคงได้รับความนิยมอย่างต่อเนื่องและถูกจัดให้เป็นมาตรฐานทองคำ (Gold Standard) ในหลายมิติ โดยเฉพาะอย่างยิ่งในด้านความสามารถในการอธิบายผลลัพธ์ (Interpretability) และความเชื่อมโยงกับทฤษฎีทางจิตวิทยาการเรียนรู้ ซึ่งเครือข่ายประสาทเทียมเชิงลึกไม่สามารถให้ความโปร่งใสในระดับนี้ได้¹ พารามิเตอร์ทุกตัวใน BKT สะท้อนถึงกระบวนการทางปัญญาของมนุษย์อย่างเป็นรูปธรรม ทำให้ผู้จัดการศึกษาหรือนักวิทยาศาสตร์ข้อมูลสามารถดึงข้อมูลเชิงลึกเพื่อวิเคราะห์และปรับปรุงคุณภาพของสื่อการสอนได้อย่างแม่นยำ¹

โครงสร้างทางคณิตศาสตร์และพลวัตของมาร์คอฟแบบซ่อนเร้น

สถาปัตยกรรมทางคณิตศาสตร์ของ BKT อาศัยโครงสร้างของแบบจำลองมาร์คอฟแบบซ่อนเร้น (Hidden Markov Model หรือ HMM) ในการนิยามตัวแปรและการเปลี่ยนสถานะ โดยกำหนดให้มีการสร้าง HMM แยก

อิสระสำหรับแต่ละทักษะหรือองค์ประกอบความรู้ (Knowledge Component)¹ ตัวแปรแฝง $L_t \in \{0, 1\}$

ทำหน้าที่ติดตามสถานะความเชี่ยวชาญของผู้เรียนในการทำธุรกรรมหรือการโต้ตอบครั้งที่ t ในขณะที่ตัวแปรที่สังเกตได้ $obs_t \in \{0, 1\}$ สะท้อนความถูกต้องของคำตอบ¹

การทำงานของแบบจำลองนี้ถูกขับเคลื่อนด้วยพารามิเตอร์หลักสี่ประการที่มีขอบเขตความน่าจะเป็นอยู่ระหว่าง 0 ถึง 1 พารามิเตอร์ตัวแรกคือโอกาสความเชี่ยวชาญเริ่มต้น หรือ $P(L_0)$ ซึ่งหมายถึงความน่าจะเป็นที่ผู้เรียนมีค

ความรู้ในทักะนั้นๆ อยู่แล้วก่อนที่จะเริ่มเข้าสู่ระบบการเรียนรู้¹ พารามิเตอร์ตัวที่สองคืออัตราการเรียนรู้ $P(T)$ ซึ่งแทนความน่าจะเป็นที่ผู้เรียนจะเกิดการเปลี่ยนผ่านสถานะจากสถานะที่ยังไม่รู้ ไปสู่สถานะที่เชี่ยวชาญ หลังจากได้รับโอกาสในการฝึกฝนหรือการอ่านผลป้อนกลับจากระบบ¹

ในส่วนของการแสดงออกทางพฤติกรรม (Emission Probabilities) แบบจำลองได้พิจารณาถึงความไม่

สมบูรณ์ของการประเมินผลผ่านพารามิเตอร์การเดา $P(G)$ และพารามิเตอร์การพลั้งเผลอ $P(S)$ โดย $P(G)$ คือความน่าจะเป็นที่ผู้เรียนจะบังเอิญตอบคำถามได้อย่างถูกต้องแม้จะยังขาดความเข้าใจในทักะนั้นๆ ซึ่ง

มักพบได้บ่อยในรูปแบบข้อสอบปรนัย ในทางกลับกัน $P(S)$ สะท้อนความน่าจะเป็นที่ผู้เรียนมีความรู้ครบถ้วน แต่กลับตอบผิดเนื่องจากความประมาท ความเหนื่อยล้า หรือความสับสนในโครงสร้างประโยคของโจทย์คำถาม¹ การปรับปรุงสถานะความรู้แบบเรียลไทม์ดำเนินการผ่านทฤษฎีบทของเบย์ (Bayes' Rule) โดยระบบจะคำนวณ

ความน่าจะเป็นภายหลัง (Posterior Probability) ของสถานะความรู้ $P(L_t|obs_t)$ ตามผลลัพธ์เชิงประจักษ์

ในกรณีที่ผู้เรียนตอบคำถามถูกต้อง ($obs_t = 1$) สมการการปรับปรุงสถานะจะพิจารณาการประเมินร่วมระหว่างความน่าจะเป็นที่ผู้เรียนรู้จริงแล้วไม่พลาด กับความน่าจะเป็นที่ผู้เรียนไม่รู้แต่วางนัยการเดาได้ถูก ดังนี้¹:

$$P(L_t|obs_t = 1) = \frac{P(L_t)(1 - P(S))}{P(L_t)(1 - P(S)) + (1 - P(L_t))P(G)}$$

ในทิศทางกลับกัน หากผลลัพธ์ปรากฏว่าผู้เรียนตอบผิด ($obs_t = 0$) ความน่าจะเป็นที่จะยังคงมีความรู้ความเชี่ยวชาญอยู่จะถูกปรับลดลงผ่านการชั่งน้ำหนักระหว่างโอกาสการพลั้งเผลอและการไม่รู้จริง¹:

$$P(L_t|obs_t = 0) = \frac{P(L_t)P(S)}{P(L_t)P(S) + (1 - P(L_t))(1 - P(G))}$$

ภายหลังการปรับปรุงความเชื่อมั่นในสถานะความรู้ ณ เวลาปัจจุบันแล้ว ขั้นตอนสุดท้ายของรอบloopคือการผสาน

พลวัตของการเรียนรู้ที่เกิดขึ้นในโอกาสนั้น โดยความน่าจะเป็นของสถานะความรู้ในลำดับถัดไป $P(L_{t+1})$ จะเกิดจากผลรวมของความน่าจะเป็นที่ผู้เรียนทราบเนื้อหาอยู่แล้ว กับความน่าจะเป็นที่ผู้เรียนเพิ่งเกิดความเข้าใจใหม่จากเนื้อหาที่ได้รับ¹:

$$P(L_{t+1}) = P(L_t|obs_t) + (1 - P(L_t|obs_t))P(T)$$

นอกจากนี้ การวิเคราะห์เชิงทฤษฎีในวงการสถิติการวัดผลยังเผยให้เห็นปรากฏการณ์จุดตรึง (Fixed Point Analysis) ของสมการเหล่านี้ เมื่อทำการแก้สมการในรูปแบบฟังก์ชันทางวิเคราะห์ (Analytical Solution) ความ

น่าจะเป็นที่ผู้เรียนจะตอบถูกในการโต้ตอบที่ j หรือ $P(C_j)$ จะมีลักษณะเป็นฟังก์ชันเอกซ์โพเนนเชียล

ที่ประกอบด้วยเทอม $1 - P(S) - Ae^{-\beta j}$ ซึ่งความเรียบง่ายทางคณิตศาสตร์นี้นำไปสู่การเชื่อมโยง

อันเป็นฐานรากสำคัญกับทฤษฎีการตอบสนองข้อสอบ (Item Response Theory หรือ IRT)⁴ งานวิจัยพบว่าการกระจายตัวแบบนิ่ง (Stationary Distribution) ของกระบวนการมาร์คอฟใน BKT เมื่อนำการลิมิตมาพิจารณาจะให้ผลลัพธ์สมการที่ลดรูปเข้าสู่โครงสร้างลักษณะโค้งลอจิสติก (Logistic Form) ซึ่งเป็นเส้นโค้งอธิบายคุณลักษณะข้อสอบ (Item Characteristic Curve) แบบเดียวกับที่ใช้ใน IRT อย่างสมบูรณ์ เป็นการยืนยันถึงความรัดกุมของ BKT ในมิติของความถูกต้องทางสถิติระดับสากล¹

ปัญหาข้อบกพร่องทางพารามิเตอร์และการปฏิบัติด้วยคณิตศาสตร์ปฐมภูมิ

แม้ว่าพื้นฐานทางคณิตศาสตร์ของ BKT จะมีความสอดคล้องกับพฤติกรรมมนุษย์ แต่อุปสรรคที่ใหญ่ที่สุดของการใช้งานในโลกความเป็นจริงคือกระบวนการเรียนรู้ค่าพารามิเตอร์ (Parameter Estimation) จากข้อมูลประวัติในอดีต แบบจำลอง BKT โดยทั่วไปใช้อัลกอริทึม Expectation-Maximization (EM) ซึ่งบางครั้งรู้จักกันในนามอัลกอริทึม Baum-Welch สำหรับการหาจุดที่ให้ค่าความควรจะเป็นสูงสุด (Maximum Likelihood)² แต่ข้อเสียเปรียบหลักของ EM คือความเปราะบางต่อค่าเริ่มต้น (Initial Values) และการตกหลุมพรางในจุดต่ำสุดระดับท้องถิ่น (Local Minima) ซึ่งทำให้เกิดปัญหาโครงสร้างที่ไม่สามารถระบุเอกลักษณ์ได้ (Identifiability Problem) หมายความว่าอาจมีพารามิเตอร์หลายชุดที่อธิบายอัตราการเกิดข้อผิดพลาดของนักเรียนได้เหมือนกันทุกประการ² ความเสี่ยงร้ายแรงที่สืบเนื่องมาจากกลไกดังกล่าวคือปรากฏการณ์พารามิเตอร์เสื่อมถอย (Degenerate Parameters) ซึ่งหมายถึงชุดพารามิเตอร์ที่สามารถปรับให้พอดี (Fit) กับข้อมูลทางสถิติได้ดีเยี่ยม แต่วิธีและขั้นตอนความเป็นจริงทางแนวคิดของมนุษย์อย่างสิ้นเชิง ตัวอย่างที่พบบ่อยที่สุดคือ อัลกอริทึมอาจประเมินค่าออกมาว่าผู้เรียนที่ไม่รู้จักกะ มีแนวโน้มที่จะตอบคำถามข้อนั้นได้ถูกต้องมากกว่าผู้เรียนที่เชี่ยวชาญทักษะนี้ไปแล้ว (

$P(G) > 1 - P(S)$) การปล่อยให้ระบบอนุমানตรรกะที่บิดเบี้ยวนี้เข้าสู่การทำงานจริง จะก่อให้เกิดการให้คำแนะนำทางวิชาการที่ผิดพลาดอย่างร้ายแรงต่อเด็กนักเรียน⁶

เพื่อรับมือกับวิกฤตทางพารามิเตอร์ งานวิจัยใหม่ล่าสุดที่ได้รับการนำเสนอในการประชุม EDM (Educational Data Mining) ปี 2024 โดย Shchepakina และคณะ ได้ปฏิวัติวิธีการมองแบบจำลองนี้ใหม่ทั้งหมดผ่านมุมมองของคณิตศาสตร์ปฐมภูมิ (First Principles)⁶ แทนที่จะพยายามแก้ไขผลลัพธ์ภายหลัง ผู้วิจัยได้นำกฎพื้นฐานเชิงความน่าจะเป็นมาผนวกกับพฤติกรรมเชิงแนวคิดที่ระบบ ITS คาดหวัง เพื่อสกัดโครงสร้างข้อจำกัดเชิงพารามิเตอร์ (Parametric Constraints) ที่จำเป็นออกมาล่วงหน้า ยกตัวอย่างเช่น การกำหนดเงื่อนไขบังคับทิศทางของการเรียนรู้ให้ต้องมีทิศทางบวกเสมอ ส่งผลให้เกิดข้อบังคับคณิตศาสตร์เชิงเส้นว่าผลรวมของโอกาสการเดาและโอกาส

การพลั้งเผลอต้องมีค่าน้อยกว่าหนึ่งเสมอ ($P(G) + P(S) < 1$) รวมถึงพื้นที่รูปสี่เหลี่ยมมุมฉากแห่งความเป็นไปได้ที่ตีกรอบค่าความรู้เริ่มต้นและการเดาให้อยู่ในขอบเขตที่สมเหตุสมผลเท่านั้น⁴

การค้นพบข้อจำกัดปฐมภูมินี้ยังนำไปสู่การพัฒนาอัลกอริทึมการเพิ่มประสิทธิภาพรูปแบบใหม่ที่ละทิ้งการทำงานแบบ EM คลาสสิก หันไปใช้การผนวก Interior-Point Method เข้ากับกระบวนการ Expectation-Maximization ซึ่งวิธีการใหม่นี้ทำหน้าที่เสมือนเกราะคุ้มกันที่ปฏิเสธเส้นทางการคำนวณใดๆ ที่นำไปสู่สถานะเสื่อมถอยระหว่างการค้นหาพารามิเตอร์ ผลลัพธ์ที่ได้จึงมิใช่เพียงความแม่นยำที่ถูกต้องตามหลักพฤติกรรมศาสตร์อย่างแท้จริงเท่านั้น แต่ยังลดต้นทุนการประมวลผล (Computational Cost) ในระหว่างกระบวนการ Fit ได้อย่างมหาศาล เนื่องจากพื้นที่ความน่าจะเป็นที่ไร้สาระถูกตัดออกจากการคำนวณตั้งแต่เริ่มต้น ถือเป็นความก้าวหน้าที่ทำให้ BKT มีความน่าเชื่อถือสำหรับการปรับใช้ในสเกลระดับชาติ⁶

ความก้าวหน้าของ BKT สมัยใหม่: ส่วนขยายและแบบจำลองเชิงลำดับชั้น

แนวทาง BKT ดั้งเดิม (Standard BKT) ตั้งอยู่บนสมมติฐานของการหลอมรวมข้อมูลที่แข็งแกร่งเกินไป นั่นคือการกำหนดให้พารามิเตอร์เพียงชุดเดียว (ความรู้เริ่มต้น การเรียนรู้ การเดา การพลั้งเพลอ) ถูกใช้งานร่วมกันครอบคลุมผู้เรียนทุกคนและแบบฝึกหัดทุกข้อภายใต้ทักษะเดียวกัน¹ สมมติฐานเชิงความเป็นเนื้อเดียวกัน (Homogeneity) เช่นนี้ ไม่สามารถสะท้อนภาพความซับซ้อนในห้องเรียนที่มีผู้เรียนมาจากภูมิหลังที่แตกต่างกัน หรือโจทย์คณิตศาสตร์บางข้อที่มีรูปภาพประกอบทำให้เดาได้ง่ายกว่าปกติ วิวัฒนาการร่วมสมัยจึงผลักดันให้ BKT แตกแขนงออกเป็นส่วยขยายย่อยที่ยอมรับการตั้งค่าความเฉพาะเจาะจง (Individualization) อย่างสมบูรณ์แบบ¹

คุณสมบัติทางสถาปัตยกรรม	แนวทางดั้งเดิม (Classical BKT)	ส่วนขยายร่วมสมัย (Extended/Hierarchical BKT)	โมเดลเครือข่ายประสาทลึก (Deep KT)
โครงสร้างความรู้และพารามิเตอร์	ทวิภาคและใช้ชุดพารามิเตอร์เดียวต่อทักษะ	ทวิภาคพร้อมโครงสร้างหลายระดับชั้น (นักเรียน, บริบท ข้อสอบ, กลุ่ม)	เป็นค่าต่อเนื่องเชิงเวกเตอร์ (คลุ่มเครือข่ายทางจิตวิทยา)
อิทธิพลของความยากของคำถาม	ไม่ถูกพิจารณา	บูรณาการผ่าน KT-IDEM หรือการจัดกลุ่มไอเทม	ผสมผสานอย่างไม่เด่นชัดในการฝึกเครือข่าย
การจัดการกับอัตราการเรียนรู้	ระบบถือว่าเรียนแล้วเรียนเลยตลอดไป	สามารถกำหนดโครงสร้าง $P(F)$ หรือแบบจำลอง BKT+Forgets	องค์ประกอบเครือข่าย RNN ครอบคลุมกลไกการเรียนรู้
การระบุความไม่แน่นอนของการทำนาย	ประเมินด้วยความน่าจะเป็นพื้นฐาน	สามารถสร้างช่วงความเชื่อมั่น (Posterior Credible Intervals)	การหาความไม่แน่นอนทางสถิติทำได้ยากและซับซ้อน
ศักยภาพด้านความเท่าเทียม (Equity)	ใช้มาตรการเดียวกับคนทุกกลุ่ม	ปรับเปลี่ยนนโยบายการเรียนรู้ออนไลน์ได้ตามรายบุคคล	ไม่ได้ให้ความสำคัญกับการสร้างโมเดลความเป็นธรรม

ตารางที่ 1 แสดงการเปรียบเทียบขีดความสามารถของแนวทาง BKT แต่ละยุคเทียบกับแบบจำลองร่วมสมัย¹ โดยส่วนขยายของ BKT ที่ได้รับการพิสูจน์แล้วว่าส่งผลต่อประสิทธิภาพสูงสุด ประกอบด้วยแนวทางที่สำคัญดังนี้:

1. สถาปัตยกรรมอิทธิพลระดับคำถามและนักเรียน (Item and Student Effects): แบบจำลอง KT-IDEM (Item Difficulty Effect Model) ได้รับการพัฒนาเพื่อแก้ปัญหาระดับคำถาม โดยอนุญาตให้สามารถประเมิน

พารามิเตอร์การเดา ($P(G)$) และการพลั้งเพลอ ($P(S)$) ที่แตกต่างกันออกไปในแต่ละแบบฝึกหัด (Item) หรือเทมเพลต ภายใต้ทักษะเดียวกัน ทำให้สะท้อนความจริงที่ว่าแบบทดสอบที่มีตัวลวงดีจะทำให้โอกาสการเดาถูก

ลดลง ในขณะเดียวกัน โมเดล KT-PPS (Prior Per Student) พยายามสร้างความยุติธรรมให้กับผู้เรียน โดยปรับให้โอกาสเริ่มต้น ($P(L_0)$) ยึดหยุ่นตามลักษณะนิสัยส่วนบุคคลหรือความสามารถดั้งเดิมของผู้เรียนแต่ละคน ก่อนใช้งาน³ ส่วน Item Learning Effect Model ช่วยประเมินว่าเนื้อหาสื่อการสอน หรือวิดีโอคลิป แต่ละตัวให้อัตราผลสัมฤทธิ์ในการเรียนรู้ ($P(T)$) ที่ต่างกันอย่างไร ซึ่งเหมาะมากกับการประเมินผลประสิทธิภาพของสื่อการสอน (A/B Testing ทางการศึกษา)⁷

2. กระบวนการย้อนกลับของความจำ (BKT+Forgets): หนึ่งใน การปรับปรุงที่เรียบง่ายแต่ทรงพลังที่สุดคือการถอดข้อจำกัดที่ว่าความรู้มีความคงทนถาวรออกไป โมเดล BKT+Forgets เพิ่มพารามิเตอร์โอกาสการลืม ($P(F)$)

เข้าสู่รูปของ HMM ทำให้สามารถจำลองสถานการณ์ที่นักเรียนทั้งช่วงการทำแบบทดสอบไปเป็นเวลาจนเกิดอาการลืมเนื้อหา งานวิจัยพบว่าเพียงแค่เปิดกลไกการลืมนี้ ประสิทธิภาพในการประเมินด้วยค่า AUC ของ BKT ก็สามารถก้าวกระโดดขึ้นมาเทียบเท่ากับเครือข่ายประสาทเทียม DKT ได้ในหลายชุดข้อมูล³

3. Spectral BKT และการสังเกตเชิงสเปกตรัม: เพื่อจัดการกับปัญหาข้อมูลปนเปื้อนความผิดปกติ (Noise) มีความพยายามสร้างตัวแปรของแบบจำลองที่ชื่อว่า Spectral BKT ซึ่งแทนที่จะดูการตอบถูกผิดเป็นรายครั้ง กลับพิจารณาสังเกตผ่านสเปกตรัมหรือการจัดกลุ่มของประวัติคำตอบติดกัน (n-grams) เช่น การดูภาพรวมของคำตอบ 3 ข้อล่าสุด (3-grams) แทนข้อมูลเดี่ยว ซึ่งช่วยเกลี่ยระดับความผิดปกติของสถิติ นำไปสู่การเข้าใจค่าความแม่นยำที่แท้จริงได้มากขึ้น และให้ผลการพยากรณ์ข้อมูลในอดีต (เช่น ข้อมูล KDD Cup 2010) ที่โดดเด่นกว่าอัลกอริทึมมาตรฐาน²

4. StanBKT และสถาปัตยกรรมแบบจำลองลำดับชั้นแบบเบย์เซียน (Hierarchical Bayesian Modeling): เมื่อจำนวนของพารามิเตอร์เพิ่มขึ้นตามรายบุคคลหรือข้อสอบ ปัญหาใหม่ก็ตามมาคือจำนวนประวัติการตอบคำถามอาจมีไม่เพียงพอต่อการประมาณค่า (Data Sparsity) ก่อให้เกิดปัญหา Overfitting อย่างหนัก โครงสร้าง StanBKT ถูกเสนอขึ้นเพื่อแบ่งกรอบโครงสร้างเป็นสามตระกูลหลัก ได้แก่ Standard, Multi, และ Hierarchical⁵ สถาปัตยกรรมระดับ Hierarchical BKT ปฏิบัติการประมาณค่าพารามิเตอร์ด้วยเทคนิคการรวบรวมข้อมูลบางส่วน

(Partial Pooling) โดยนิยามว่าค่าพารามิเตอร์ ϕ_j สำหรับกลุ่ม j จะถูกอธิบายผ่านสมการลอจิสติก (Logit):

$$\text{logit}(\phi_j) = \text{logit}(\phi_0) + \delta_{\phi_j}, \quad \delta_{\phi_j} \sim \mathcal{N}(0, \sigma_\phi^2)$$

ในบริบทนี้ ϕ_0 ทำหน้าที่เป็นตัวแทนของคุณลักษณะภาพรวมของประชากรระดับโลก ในขณะที่ δ_{ϕ_j} สะท้อนค่า

ความเบี่ยงเบนเฉพาะกลุ่ม โดยมีพารามิเตอร์ความแปรปรวน σ_ϕ^2 เป็นตัวควบคุมระดับความหดตัว (Shrinkage Degree) หากนักเรียนคนใดมีข้อมูลตอบคำถามน้อยมาก ระบบจะบีบการประมาณค่าให้ลู่เข้าหาแกนประชากร

ϕ_0 โดยอัตโนมัติ ซึ่งปกป้องระบบจากการด่วนสรุปพฤติกรรมนักเรียนที่เพิ่งเข้ามาใหม่ เป็นการเพิ่มระดับสถิติเชิงอนุมานที่มีความเสถียรสูงสุด¹

คู่มือการพัฒนาและปฏิบัติการวิศวกรรมข้อมูลด้วย pyBKT

เพื่อรับมือกับความท้าทายในการนำโมเดล BKT ไปผนวกกับระบบปฏิบัติการจริง มหาวิทยาลัยแคลิฟอร์เนีย เบิร์กลีย์ (UC Berkeley) ได้บุกเบิกและพัฒนาชุดซอฟต์แวร์ต้นแบบเชิงอุตสาหกรรมในชื่อ pyBKT ซึ่งเป็นไลบรารีที่เขียนด้วยภาษา Python โดยมีการเชื่อมต่อแบ็กเอนด์ด้วยภาษา C++ ผ่าน Libboost เพื่อการประมวลผลอัลกอริทึม HMM Forward-Backward ที่ขนานและรวดเร็ว⁷ ประสิทธิภาพของการแปลงกระบวนการนี้ ส่งผลให้

ระยะเวลาในการฝึกฝนข้อมูลนักเรียน 5,000 คน ถูกย่นระยะจากเกือบชั่วโมงครึ่งใน Python บริสุทธิ์ เหลือเพียง 45 วินาทีเมื่อเรียกใช้ส่วนต่อขยาย C++¹⁴ ไลบรารีนี้ถูกออกแบบภายใต้มาตรฐานอินเทอร์เน็ตเพชเดียวกับ scikit-learn เพื่อสร้างสภาพแวดล้อมที่คุ้นเคยให้กับวิศวกรการเรียนรู้ของเครื่อง³ นอกจากนี้ยังมีการพอร์ตข้ามไปยังสภาพแวดล้อมสถิติ R ผ่านแพ็คเกจ BKT อีกด้วย¹⁵

โครงสร้างและวงจรการเตรียมข้อมูลเชิงสัมพันธ์

กลไกภายในของ pyBKT คาดหวังการป้อนตารางข้อมูล (Data Matrix) ที่มีความแม่นยำทางมิติเวลา การป้อนชุดข้อมูลทั่วไปที่เป็นสกุล CSV จะถูกประมวลผลย่อยลงสู่คลาส Data เชิงวัตถุ ซึ่งซ่อนโครงสร้างอาร์เรย์ที่ซับซ้อนไว้ภายใน¹² โครงสร้างข้อมูลแกนกลางที่จัดการมิติของเวลาและผู้เรียนจะประกอบไปด้วยเวกเตอร์ต่อไปนี้:

คุณลักษณะโครงสร้างข้อมูล	บทบาทและการแสดงผลทางเมทริกซ์ในกระบวนการ EM
data	เมทริกซ์การตอบรับแบบลำดับเวลา แต่ละแถวแทนคำถามย่อย (Subparts) แต่ละคอลัมน์แทนจุดตรวจประเมินเวลาของนักเรียน มีสถานะคือ 0 (ไม่มีกิจกรรม), 1 (ตอบผิด), และ 2 (ตอบถูก)
starts	เวกเตอร์หนึ่งมิติที่กำหนดหน้าที่เป็นพอยน์เตอร์ชี้ว่าบันทึกประวัติการเริ่มทำข้อสอบของนักเรียนรายที่ i เริ่มขึ้นที่คอลัมน์ดัชนีใดในเมทริกซ์ data
lengths	เวกเตอร์ที่ระบุจำนวนจุดตรวจสอบหรือปริมาณข้อมูลในกระบวนการเวลา (Timesteps) ของผู้เรียนแต่ละคน
resources	ลำดับตัวเลขประจำตัวสื่อการสอน หรือประเภทคำถามที่ถูกหยิบใช้ ณ เวลาในแต่ละจุดตรวจสอบ (ใช้วางแผนไข่อัตราการเรียนรู้แบบ Multilearn)
stateseqs	เวกเตอร์สถานะความเชี่ยวชาญที่แท้จริงของผู้เรียน (ในระบบปกติจะถูกเว้นว่างไว้เพื่อรอการอนุมานโดยรูปแบบ EM)

ตารางที่ 2 อธิบายอาร์เรย์ทางคณิตศาสตร์ที่โปรแกรมประยุกต์จัดเตรียมไว้เบื้องหลัง¹² อย่างไรก็ตาม นักพัฒนาเพียงแค่อโหลดข้อมูลผู้เรียนในรูปแบบ Pandas DataFrame แบบราบ (Flat Table) และไลบรารีจะจัดการสร้างเมทริกซ์เหล่านี้โดยอัตโนมัติ

กระบวนการฝึกฝนแบบจำลองเชิงโค้ดและการกำหนดค่าแผนผัง (Model Fitting & Mapping)

เนื่องจากระบบการศึกษาแต่ละแห่งมีมาตรฐานการตั้งชื่อฐานข้อมูลที่แตกต่างกัน ขั้นตอนแรกของการนำไปปฏิบัติคือการแมปคอลัมน์ข้อมูลเข้าสู่โครงสร้างที่อัลกอริทึมคุ้นเคยผ่านดิกชันนารี (Dictionary) ที่เรียกว่า defaults ซึ่งพารามิเตอร์มาตรฐานทั้งสี่ที่จำเป็นคือ ลำดับเวลา (order_id), ชื่อทักษะ (skill_name), ผลลัพธ์ความถูกต้อง (correct) และรหัสผู้เรียน (user_id)¹⁵

การประกาศสร้างแบบจำลองและการกระตุ้นวงจรการเรียนรู้ EM สามารถดำเนินการอย่างสง่างามผ่านตัวอย่างภาษา Python ดังต่อไปนี้:

Python

```
import pandas as pd
from pyBKT.models import Model

# อ่านข้อมูลประวัติผู้เรียน
dt = pd.read_csv('mystery_tutor_dataset.csv')

# การสร้างพจนานุกรมเพื่อผูกพารามิเตอร์ระหว่างไฟล์กับโมเดล
defaults = {
    'order_id' 'timestamp_row'
    'skill_name' 'knowledge_component'
    'correct' 'is_correct'
    'user_id' 'student_id'
}

# เปิดพีเจอร์ KT-IDEM: ใช้คอลัมน์ 'item_type' สำหรับแบ่งคลาสพารามิเตอร์ Guess และ Slip
defaults['multigs'] = 'item_type'

# กำหนด Seed สร้างความสามารถในการประเมินซ้ำแบบคงที่
model = Model(seed=42, num_multis=5)

# สั่งประมวลผลอัลกอริทึม HMM ผสานกับ EM สำหรับบางทักษะที่เจาะจง
model.fit(
    data=dt,
    defaults=defaults,
    skills=["Plot imperfect radical" "Volume Cylinder"]
    multigs=True # อนุญาตให้คำถามแต่ละชนิดเดาและพลั้งเผลอได้ไม่เท่ากัน
    forgets=True # อนุญาตให้อัตราการลืมมีอยู่จริงในการประเมิน
    multilearn='Anon Student Id' # ระบุว่าอัตราการเรียนรู้แปรผันตามผู้เรียนเป็นรายบุคคล (KT-PPS ประยุกต์)
```

พารามิเตอร์อาร์กิวเมนต์ที่ซับซ้อนอย่าง multilearn หรือ multigs หากถูกกำหนดค่าเป็นตรรกะ True ระบบจะพยายามค้นหาการแบ่งคลาสโดยอัตโนมัติจากโครงสร้าง defaults แต่หากระบุชื่อคอลัมน์โดยตรง ระบบจะสับเปลี่ยนพารามิเตอร์แบบจำลองให้แปรผันตามหมวดหมู่ข้อมูลในคอลัมน์นั้นทันที ก่อให้เกิดเครือข่าย HMM ขนานจำนวนมหาศาลที่ถูกบริหารจัดการภายในหน่วยความจำอย่างมีประสิทธิภาพ³

การสกัดพารามิเตอร์และการประเมินความสมเหตุสมผลของระบบ

ความลึกซึ้งทางด้านการให้เหตุผลของ BKT ยิ่งชัดเจนขึ้นเมื่อเราทำการดึงพารามิเตอร์มาวิเคราะห์ภายหลังการบรรจบกันของสมการ EM การใช้งานเมธอด model.params() จะให้คืนค่าสถิติในรูปแบบตาราง DataFrame เชิงสัมพันธ์ที่แจ่มเจนน้าหนักทางปัญญารายทักษะ¹⁷

ทักษะ (skill)	พารามิเตอร์ (param)	คลาส (class)	ค่าประมาณการ (value)
Volume Cylinder	prior	default	0.17452
Volume Cylinder	learns	default	0.13378
Volume Cylinder	guesses	default	0.25502
Volume Cylinder	slips	default	0.05422
Volume Cylinder	forgets	default	0.00000

ตารางที่ 3 จำลองสถาปัตยกรรมข้อมูลผลลัพธ์ของพารามิเตอร์⁷ การสะท้อนผลเชิงวิเคราะห์จากค่าในตารางสามารถช่วยผู้ออกแบบหลักสูตรได้โดยตรง เช่น หากค่าการเดา (guesses) สูงผิดปกติถึง 0.25 ย่อมหมายความว่าข้อสอบที่ประเมินปริมาตรทรงกระบอกอาจมีตัวเลือกแบบปรนัยที่ง่ายเกินไปจนชี้ช่องให้นักเรียนเดาถูก หรือหากอัตราการเรียนรู้ (learns) ต่ำเพียง 0.13 อาจบ่งบอกว่าสื่อการสอนในบทเรียนนั้นไม่สามารถถ่ายทอดองค์ความรู้ได้อย่างมีประสิทธิภาพเพียงพอ³ ยิ่งไปกว่านั้น pyBKT มีฟีเจอร์การติกรอบความรู้ (Parameter Fixing) ผ่านการตั้งค่า model.coef_ เพื่อบังคับให้พารามิเตอร์ตัวใดตัวหนึ่ง (เช่น บังคับการเดาให้เป็นศูนย์) ถูกบล็อกไว้ตายตัวสำหรับทักษะบางประเภท ป้องกันไม่ให้ EM ปรับค่าในทิศทางที่ไม่พึงประสงค์¹⁷

ตัวชี้วัดสมรรถนะเชิงทำนาย (Predictive Performance Evaluation)

สำหรับการประเมินระดับสากล แบบจำลอง BKT พึ่งพากระบวนการตรวจสอบความถูกต้องไขว้ (Cross-Validation) แบบอัตโนมัติ โดยแบ่งกลุ่มตัวอย่างด้วยกลไก K-Folds ฟังก์ชัน .crossvalidate() รองรับตัวชี้วัดประสิทธิภาพหลักสามรูปแบบ ได้แก่ ความแม่นยำสัมบูรณ์ (Accuracy), ค่าความแปรปรวนของความผิดพลาด (RMSE), และพื้นที่ใต้กราฟ (AUC) รวมไปถึงการยอมรับฟังก์ชันที่นิยามขึ้นเอง เช่น ผลรวมกำลังสองของส่วนตกค้าง (SSR)¹⁹ การทดสอบเชิงประจักษ์โดยใช้ข้อมูลการใช้งานจริงของระบบ ASSISTments 2009-2010 แสดงให้เห็นว่าการใช้ชุดดั้งเดิมสามารถมอบผลลัพธ์ AUC อยู่ที่ 0.76 แต่เมื่อระบบผนวกรวมความซับซ้อนในมิติของการลืม (forgets=True) ความแม่นยำในการระบุทักษะจะกระโดดขึ้นไปแตะที่ AUC 0.83 อย่างชัดเจน และเมื่อเจาะจงใช้ KT-IDEM ในทักษะที่มีโจทย์หลากหลาย รูปแบบนี้สามารถลดค่าความคลาดเคลื่อน RMSE ลงได้อย่างเป็น

รูปธรรมเมื่อเทียบกับสแตนด์ดาร์ดโมเดล¹³

วิสัยทัศน์และการประยุกต์ใช้งานล่วงหน้า (Prediction and Roster Simulation)

จุดประสงค์สุดท้ายที่ระบบ ITS ทุกระบบต้องการคือ การทำนายพฤติกรรมอนาคตของผู้เรียน เมื่อใช้ฟังก์ชัน `.predict()` บนชุดข้อมูลประวัติ ระบบจะพาสานพารามิเตอร์เข้าไปสร้างคอลัมน์ใหม่สองมิติ ได้แก่ `correct_predictions` ซึ่งเป็นการทำนายความเป็นไปได้ที่ผู้เรียนคนนั้นจะตอบโจทย์ปัญหาถัดไปได้ถูกต้อง และไฮไลต์สำคัญคือ `state_predictions` ซึ่งสะท้อนความน่าจะเป็นทางสถิติว่าสถานะความเชี่ยวชาญของผู้เรียนทะลุเกณฑ์มาตรฐานแล้วหรือยัง¹⁵ ระบบสอนเสริมล้ำยุคจะสร้างเงื่อนไขตรวจสอบว่า หากค่า `state_predictions` เข้าใกล้หรือมากกว่า 0.95 ระบบจะหยุดจ่ายแบบฝึกหัดในบทเรียนนั้น และเลื่อนระดับชั้นของผู้เรียนขึ้นโดยอัตโนมัติ⁴ นอกจากนี้ เพื่อการทดสอบนวัตกรรมแบบจำลองในห้องปฏิบัติการ pyBKT จึงสร้างคลาส Roster เพื่อใช้จำลองบรรยากาศสภาพแวดล้อมเสมือนจริงของกลุ่มผู้เรียนเป้าหมาย ทำให้นักวิจัยสามารถติดตามสถานะพัฒนาการความเชี่ยวชาญของรายชื่อนักเรียนสมมติที่มีภูมิหลังต่างกันเมื่อพวกเขาถูกทิ้งให้เผชิญกับชุดทักษะอันหลากหลาย

17

บทสรุป

Bayesian Knowledge Tracing (BKT) มิใช่เพียงร่องรอยของทฤษฎีในอดีต แต่เป็นสถาปัตยกรรมคณิตศาสตร์แห่งความน่าจะเป็นที่มีชีวิตและการพัฒนาอย่างไม่หยุดนิ่ง จากรากฐานอันเรียบง่ายของมาร์คอฟแบบซ่อนเร้น มันได้วิวัฒนาการผ่านการแก้ไขข้อบกพร่องของความเสื่อมถอยของพารามิเตอร์ด้วยกรอบคณิตศาสตร์ปฐมภูมิ (First Principles Constraints) ควบคู่ไปกับ Interior-Point Method ที่รับประกันความมั่นคงของคุณค่าเชิงพฤติกรรม⁶

การขยายปีกของ BKT ผ่านส่วนขยายแบบกำหนดค่ารายบุคคลอย่าง KT-IDEM และ KT-PPS ไปจนถึงกลไกลำดับชั้น (StanBKT) ทำให้ขอบเขตของการเข้าถึงความโปร่งใสในปัญญาของมนุษย์มีความลึกซึ้งในระดับที่ไม่เคยประสบความสำเร็จมาก่อน¹ สุดท้าย การเกิดขึ้นของซอฟต์แวร์แบบโอเพนซอร์สประมวลผลสูงอย่าง pyBKT ได้ทำลายกำแพงแห่งการทดลอง ทำให้องค์กรทางเทคโนโลยีและวิศวกรผู้สร้างผลิตภัณฑ์การศึกษาสามารถบูรณาการโมเดลวิเคราะห์ความเชี่ยวชาญที่มีคุณภาพระดับงานวิจัยโลก เข้าสู่วงจรผลิตภัณฑ์ปัญญาประดิษฐ์ทางการเรียนรู้ของตนเองได้เพียงปลายนิ้วสัมผัส ก่อเกิดความเป็นธรรมและความเท่าเทียมในการศึกษาที่ได้รับการผลักดันด้วยพลวัตของข้อมูลอย่างแท้จริง¹

ผลงานที่อ้างอิง

1. Bayesian Knowledge Tracing - Emergent Mind, <https://www.emergentmind.com/topics/bayesian-knowledge-tracing>
2. Spectral Bayesian Knowledge Tracing - University of Pittsburgh, <https://people.cs.pitt.edu/~falakmasir/docs/EDM2015.pdf>
3. pyBKT: An Accessible Python Library of Bayesian Knowledge Tracing Models - Educational Data Mining, https://educationaldatamining.org/EDM2021/virtual/static/pdf/EDM21_paper_237.pdf
4. Properties of the Bayesian Knowledge Tracing Model - ERIC, <https://files.eric.ed.gov/fulltext/EJ1115329.pdf>
5. StanBKT: Rethinking Parameter Estimation in Bayesian Knowledge Tracing - arXiv, <https://arxiv.org/html/2605.23048v1>
6. Parametric Constraints for Bayesian Knowledge Tracing from First Principles,

<https://educationaldatamining.org/edm2024/proceedings/2024.EDM-long-papers.2/index.html>

7. pyBKT: An Accessible Python Library of Bayesian Knowledge Tracing Models - ERIC, <https://files.eric.ed.gov/fulltext/ED615610.pdf>
8. Parametric Constraints for Bayesian Knowledge Tracing from First Principles - arXiv, <https://arxiv.org/html/2401.09456>
9. Parametric Constraints for Bayesian Knowledge Tracing from First Principles, <https://cdn.amazon.science/b8/25/bbd83c28452c822e4db44a7f949b/parametric-constraints-for-bayesian-knowledge-tracing-from-first-principles.pdf>
10. Parametric constraints for Bayesian knowledge tracing from first principles - Amazon Science, <https://www.amazon.science/publications/parametric-constraints-for-bayesian-knowledge-tracing-from-first-principles>
11. Parametric Constraints for Bayesian Knowledge Tracing from First Principles - Educational Data Mining, <https://educationaldatamining.org/edm2024/proceedings/2024.EDM-long-papers.2/2024.EDM-long-papers.2.pdf>
12. pyBKT - PyPI, <https://pypi.org/project/pyBKT/1.0.1/>
13. CAHLR/pyBKT-examples - GitHub, <https://github.com/CAHLR/pyBKT-examples>
14. pyBKT - PyPI, <https://pypi.org/project/pyBKT/>
15. BKT package - RDocumentation, <https://www.rdocumentation.org/packages/BKT/versions/0.1.0>
16. GitHub - Feng-Ji-Lab/BKT: Bayesian Knowledge Tracing Model in R, <https://github.com/Feng-Ji-Lab/BKT>
17. pyBKT/README.md at master - GitHub, <https://github.com/CAHLR/pyBKT/blob/master/README.md>
18. GitHub - cran/BKT: :exclamation: This is a read-only mirror of the CRAN R package repository. BKT — Bayesian Knowledge Tracing Model, <https://github.com/cran/BKT>
19. Module 1: Case Study - quarto.pub, <https://yilinl.quarto.pub/intro-to-bkt/>
20. pyBKT Model Tutorial.ipynb - Colab, <https://colab.research.google.com/drive/13abu919edUXbvPV3qeGPpwwnFBExU7Vd>
21. Package 'BKT' - Bayesian Knowledge Tracing Model - CRAN, <https://cran.csiro.au/web/packages/BKT/BKT.pdf>
22. How to get current knowledge state? · Issue #19 · CAHLR/pyBKT - GitHub, <https://github.com/CAHLR/pyBKT/issues/19>